# Apache Spark 测试规格说明书

组员:

SY1506404 孟翰

SY1506409 苏若

SY1506425 李璇

SY1506406 孙敏芳

# 目录

1	范	围	4
	1.1	标识	4
	1.2	系统概述	4
	1.3	文档概述	4
	1.4	目的	5
	1.4.1	文档目的	5
	1.4.2	测试目的	5
	1.5	引用文档	5
2	测记	式方法概述	5
3	测记	式准备	7
	3.1	软硬件环境的准备配置情况	7
	3.2	测试数据	7
	3.3	测试策略	7
	3.4	测试环境与软件运行环境的偏差	7
4	测记	式用例	8
	4.1	功能性需求测试	8
	4.2	非功能性需求测试	0
5	测计	式用例追踪	3

### 版本变更历史

版本	提交日期	主要编制人	审核人	版本说明
1.0	2016. 05. 12	孟翰、李璇、孙敏芳、苏若		初始版本 V1.0
2. 0	2016. 05. 19	孟翰、李璇、孙敏芳、苏若		V2. 0

# Apache Spark 测试规格说明书

### 1 范围

#### 1.1 标识

Spark 版本号: spark1.6.1

Spark 源码实现语言: Scala

可编程语言: Scala + Scala shell、Java、Python + Scala shell

环境: jdk1.8

测试规格说明书版本: V1.0

#### 1.2 系统概述

Spark 是 UC Berkeley AMP lab 所开源的类 Hadoop MapReduce 的通用的并行计算框架,分布式资源工作交由集群管理软件(如 Mesos, Standalone, YARN).

从整体架构而言:

第一, Spark 提供了多种高级工具,如 Shark SQL 应用于查询、Spark Streaming 应用于流式计算、MLib 应用于机器学习、GraphX 应用于图处理。

第二, Spark 可以访问存储在 HDFS、Hbase、Cassandra、Amazon S3、本地文件系统等上的数据,并支持多种文件格式,如文本文件、序列文件及 Hadoop 的 InputFormat。

从核心模块而言:

Spark 核心组件包括 RDD、Scheduler、Storage、Shuffle 四部分。

#### 1.3 文档概述

本文档主要包括以下几部分内容:

第一节, 系统地阐述了整体的系统框架及文档相关描述。

第二节, 对各种测试方法进行类梳理。

第三节,介绍了本次实验过程中相关的测试准备,主要分为:软硬件环境的准备配置情况、测试数据、测试策略和测试环境与软件运行环境的偏差四部分内容。

第四节, 为相关测试用例的介绍,可细分为功能性需求和非功能性需求两个 模块。

第五节, 为测试用例追踪,对测试需求项和测试用例建立整体追踪。

#### 1.4 目的

#### 1.4.1 文档目的

结合《需求规格说明书》中涉及到的需求和目前 Apache Spark 系统的认识,对该系统的相关需求进行了初步测试计划的设计工作,其涵盖了测试准备、测试策略、测试用例设计、测试用例追踪设计等方面内容。测试人员根据此文档可高效完成对系统的测试工作。

#### 1.4.2 测试目的

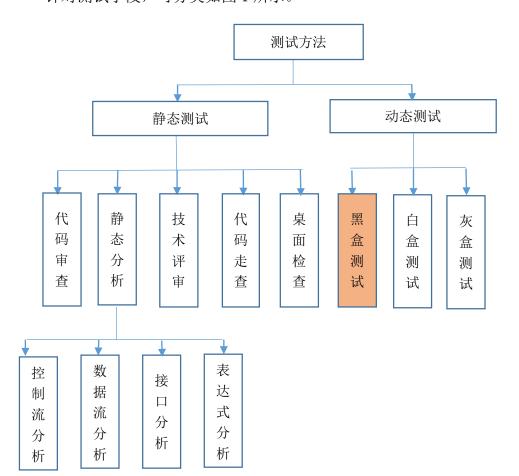
通过建立测试用例对系统进行测试,通过对产生的测试结果和系统的需求规格说明书进行比较,可以帮助我们判断系统是否满足了需求规格说明书中产生的功能性需求和非功能性需求,进而可以帮助我们发现系统中的问题并有机会对其加以改正。

#### 1.5 引用文档

- [1]许鹏,《Apache Spark 源码剖析》[M], 电子工业出版社, 2015-3
- [2] 夏俊鸾. 程浩. 邵赛赛,《Spark 大数据处理技术》[M], 电子工业出版社, 2014.12
- [3]《A-需求规格说明书-基于分布式 Apache Spark 的数据处理研究\_v4.0 修订版》

# 2 测试方法概述

针对测试手段,可分类如图1所示。



#### 图 1 测试手段分类

针对测试步骤,可分为针对编码的单元测试、针对设计的集成测试、以及针对需求分析的确认测试和系统测试。当然还包括如α测试与β测试、验收测试和人工测试等。

单元测试(模块测试)是开发者编写的一小段代码,用于检验被测代码的一个很小的、很明确的功能是否正确。

集成测试是在单元测试的基础上,测试在将所有的软件单元按照概要设计规格说明的要求组装成模块、子系统或系统的过程中各部分工作是否达到或实现相应技术指标及要求的活动。

系统测试将经过集成测试的软件,作为系统计算机的一个部分,与系统中 其他部分结合起来,是针对整个产品系统进行的测试,目的是验证系统是否满 足了需求规格的定义,找出与需求规格不符或与之矛盾的地方,从而提出更加 完善的方案。主要内容包括功能测试(依据是需求文档)、性能测试等。

本文目前进行的测试主要针对《需求规格说明书》,故采用的技术之一是黑 盒测试,其机制如图 2 所示:

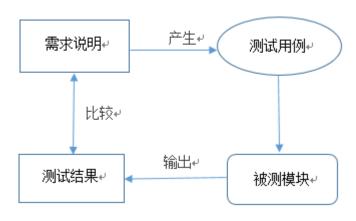


图 2 黑盒测试机制

黑盒测试的依据为:用户能看到的规格说明,针对功能进行测试。本文采用 黑盒测试的原因在于其能站在用户立场上进行、测试,注重于测试软件的功能性 需求。

此外,<mark>性能测试(负载测试+压力测试)</mark>也是本次选用的测试方法之一。性能测试是在功能正确的基础上考虑功能的响应时间、资源占用等。通过性能测试,会得到供参考的性能数据,可以验证系统是否达到用户提出的性能指标,同时发现系统中存在的性能瓶颈,起到优化系统的目的。这里,我们结合需求和经验获取性能测试指标。

# 3 测试准备

### 3.1 软硬件环境的准备配置情况

平台:Linux 平台	
节点数: 2	
cpu: i7-6700u i7-5960x	
内存分配:每台 16G	

#### 3.2 测试数据

1. Movielens 数据集

选择 Movielens 作为测试数据的原因主要体现在以下 4 个方面:

- a. 数据量大
- b. 数据来源相对权威,在一定程度上会减少测试结果的偏差
- c. 可验证机器学习的准确率
- d. 有实际应用价值
- 2. Movielens 数据集分析程序
- 3. Shark SQL 查询程序

#### 3.3 测试策略

- 1、在测试设计上,可从正常情况、非正常情况、边界情况、非法情况、极端情况(强度测试)、性能测试几个角度进行。
  - 2、对于测试完成的标准,可以从以下两方面衡量:
  - 第一、执行了所有测试情况,但没有发现错误,则停止测试。
- 第二、下述标准属于理想测试状态下,适合于测试周期较长的情况。具体来说:这一完成标准通过记录测试阶段 A 在固定时间间隔下发现问题的数量绘制曲线信息,来判断测试阶段 A 已没有发现新问题的潜力,此时可以选择进入下一测试阶段。

#### 3.4 测试环境与软件运行环境的偏差

序号	软件运行环境	测试环境	偏差对测试结果的
			影响
1			
2			
3			

# 4 测试用例

### 4.1 功能性需求测试

测试用例功能性需求测试对应需求规格说明书 V3.1

### (1)测试需求——Spark 机器学习结果测试

测试	Spark	测试	TC001	测试需	功能	测试	TR01	测记	式用例	2.3 节
用例	机器学	用例		求项	性测	需求		追記	宗 ( 需	MLib
名称	习结果	标识			试	标识		求	现格说	机器学
	测试							明-	书)	习
简要	要描述	本测试	验证 Spa	rk 机器学	习算法	付 Movie	lens 数据	集	进行训练组	吉果的精
		确度。	通过修改	训练模型	三个参	数的大小	,验证不	「同情	青况下输出	出结果差
		异。								
前提	和约束	Spark	集群配置	完成,数	据集准备	4 妥当				
测证	式方法	黑盒测	]试							
				测试	过程描述	Ł				
		测试步骤			预期结果				评价准	测试
序	序号								则 则 拒	结论
									N.J	知化
		设置S	Spark 机岩	器学习算					实际结	
	1	法对 Movielens 数据集 程序中训练模型的三个			输出方差值接近于 0				果与预	无
	1								期结果	
		参数							一致	
									实际结	
	2	调整训	练模型的	的三个参					果与预	无
Δ		数							期结果	工
									一致	
名	各注									
测试人	.员:			监测人员	₹:		测试时	间:		

## (2)测试需求——Spark 执行 SQL 数据处理

测试	Spark	测试	TC002	测试需	功能	测试	TR01	测试用例	2.3 节
用例	执行	用例		求项	性测	需求		追踪(需	Sq1 分
名称	SQL 数	标识			试	标识		求规格说	析计算
	据处理							明书)	
简要抗	苗 本测记	式 Spark	系统上运	:行 SQL 命	令,针	付不同格	式的数据	B(如 JSON	数据
述	集、数	数据库、	Hive R	DD)执行	ETL 操	作,然后	言进行增	、删、改、查	操作分
	析。								
前提利	🛘 Spark	集群配	置完成,	数据集准	备妥当				
约束									
测试力	测试方 黑盒测试								
法	法								
		-		测试	过程描述	<u></u> 尤			

使用 Spark Context 対象创建 SQLContext	无无
2成 DataFrame import sqlContext. implicits预期结果一 致3使用要进行分析的数据集文件创建一个与 数据集结构相同的对象的 DataFrame实际结果与 预期结果一 致	无
者 使用要进行分析的数据集文件创建一个与 数据集结构相同的对象的 DataFrame 致	
· · · · · · · · · · · · · · · · · · ·	无
4   使用 DataFrame 将创建的 DataFrame 注册 为一个表   预期结果一 致	无
添加增、删、改、查等操作(select、show、count)的实现函数  实际结果与 预期结果一 致	无
6 提交到集群执行,并监控执行状态 显示数据集 相应的内容 致	无
7 通过编程的方式指定数据集的模式,重新 显示数据集	无
8 对其他格式的数据集进行测试 显示数据集	无
备注      监测人员: 测试时间:	

# (3)测试需求——Spark Stream流计算测试

测试	Spark	测试	TC003	测试需	功能	测试	TR01	测试用例	2.3 节
用例	Stream	用例		求项	性测	需求		追踪(需	Stream
名称	流计算	标识			试	标识		求规格说	流计算
	测试							明书)	
简要挂	苗本洲	引试是使用	∄ Spark S	Stream 对	实时数捷	居进行高	通量的流	瓦式处理,对辅	俞入的数
述	据》	ほ (例如し	以 socket	连接作为	数据源)	进行某	种操作,	分析不同 bat	tch
	inte	rval 情况	下的效率	0					
前提和	和 Spa	rk 集群酉	門置完成,	数据集准	备妥当				
约束									
测试フ	测试方 黑盒测试								
法	法								
				测试	过程描述	尤			

序号	测试步骤	预期结果	评价准则	测试结论
1	设置工作线程数目		实际结果与 预期结果一 致	无
2	创建 StreamingContext 对象: val ssc = new StreamingContext(conf, Seconds(1)),设置 batch interval(例如 1s)指定处理数据的 时间间隔——输入数据会按照 batch interval 分成一段一段的数据		实际结果与 预期结果一 致	无
3	输入需要分析的数据源 InputDStream(可以是 Kafka、Flume、HDFS/S3、Kinesis 和Twitter 等数据源)		实际结果与 预期结果一 致	无
4	然后统计每一个 batch 中的 word 数目——Reduce	中间结果可以 输出的外部设 备	实际结果与 预期结果一 致	无
5	统计(Map)并打印统计结果(可以进行时间统计)	输出统计的结 果(和时间记 录)	实际结果与 预期结果一 致	无
6	更改 batch interval 进行测试比较	显示数据集相 应的内容	实际结果与 预期结果一 致	无
7	更改数据源进行测试比较			
备注		1		
测试人员:	: 监测人员:	Į į	训试时间:	

## 4.2 非功能性需求测试

(1)测试需求——Spark 鲁棒性测试

测试	Spark	测试	TC011	测试需	非功	测试	TR01	测试用例	6.0	3.1节
用例	鲁棒性	用例		求项	能性	需求		追踪(需		
名称	测试	标识			测试	标识		求规格说		
								明书)		
简要	描述	通过测证	式在输入非	丰法、Spa	rk 集群「	中节点故	障等情况	上下软件的运	行	情况,
		验证 Spa	ark 系统的	的鲁棒性。						
前提利	和约束									
测试	方法	性能测证	式							
				测试	过程描述	尤				
序	;号		测试步骤			预期结	果	评价准则	4444	测试 结论

1	启动 Spark Shell,输入 非法命令	提示输入命令不合法,并 返回输入命令前状态	实际结 果与预 期结果 一致	无
2	使用 hql 方法执行 hive 语句,测试是否出现 OutOfMemoryError 问题 (内存溢出)	不会引起 00M (OutOfMemoryError) 问 题	实际结 果与预 期结果 一致	无
3	使用 collect 操作,将 所有 executor 的数据聚 合到 driver,测试是否 异常	不出现异常	实际结 果与预 期结果 一致	无
备注				
测试人员:	监测人员:	测试时间	1	

# (2)测试需求——Spark 容错性测试

测试	Spark	测试	TC012	测试需	非功	测试	TR01	测试用例	3.2节
用例	容错性	用例		求项	能性	需求		追踪(需	
名称	测试	标识			测试	标识		求规格说	
								明书)	
简要	描述	通过测证	式在输入非	丰法、软件	井故障等	情况下转	次件的性能	比,验证 Spai	k 系统
		的容错性	ŧ.						
前提和	印约束								
测试	方法	性能测证	式						
				测试	过程描述	롼			
序	序号    测试步骤					预期结	评价准则	测试结论	
	启动 Spark Shell,输入 非法命令、非法数据源			****		入命令 <sup>7</sup> 据源不同	实际结 果与预 期结果 一致	无	
:	2	个从节	,美闭一 点,观察 端运行情况	主节点	到从节 成提为作,从	端超时经点关闭的 点关闭的 点信息, 一节点中 提交执行	生	无	
:	3		,关闭主 从节点端 况		., . ,	端生成技	实际结 果与预 期结果 一致	无	
备	·注								
测试人	 .员 <b>:</b>		监	则人员:			测试时	间:	

# (3)测试需求——Spark 安全性测试

测用名称 简要 提和	叩约束	用例标识 超过实例	TC013 引测试 Spa E全性能要		非功能性测试。保证We	测试 需求 标识 b UI 安全	TR01 全、事件	追跳求規明	·	3.3节
	测试过程描述									
序号		测试步骤			预期结果				评价准 则	测试结论
1		使用 A 用户账户设置 spark.ui.filters 参数, 启 用 javax.servlet.filters, 对 UI 进行安全设置;使用 未经过验证的用户账户 B 登录进入 Spark,并查看 A 的 UI 界面			系统进行权限确认,拒绝 B 用户查看该 UI 界面				实际结 果与预 期结果 一致	无
2	创建存放事件日志的文件 夹,为这个文件夹设置 drwxrwxrwxt 权限,使用 非文件所有者账号再该文 件夹下进行操作(读、 写、移动、重命名)					可以在该 移动和重 ‡。	I	实际结 果与预 期结果 一致	无	
利用 Spark Streaming 进行多媒体数据进行处 理			系统	要求进行	<b></b> 身份认证	Œ	实际结 果与预 期结果 一致	无		
温 湯 湯 湯 湯 湯 湯 湯 湯 湯 湯 湯 湯 湯 湯 湯 湯 湯 湯 湯			Щ	ǐ测人员:			测试印	寸间:		

# (4)测试需求——Spark 效率测试

测	间试	Spark	测试	TC014	测试需	非功	测试	TR01	测试用例	3.4节
用	例	效率测	用例		求项	能性	需求		追踪(需	
名	称	试	标识			测试	标识		求规格说	
									明书)	
	简要	描述	通过用例运行时间和结果,并对比在其他系统中运行的时间和结果,验							
	证 Spark 运行效率。									

前提和约束								
测试方法	性能测试							
测试过程描述								
序号	测试步骤	预期结果	评价准 则	测试 结论				
1	使用 Spark 对大数据文件 进行处理,同时进行运行 时间 T1 的输出		实际结 果与预 期结果 一致	无				
2	采用其他系统对相同的 大数据文件进行处理以 及处理时间 T2 输出		实际结 果与预 期结果 一致	无				
3	比较 1 和 2 中运行结果的准确率;比较 T1 和 T2 的大小	1 中运行结果准确率更 高; T1 <t2< td=""><td>实际结 果与预 期结果 一致</td><td>无</td></t2<>	实际结 果与预 期结果 一致	无				
备注				•				
测试人员:	监测人员:	测试时间	:	·				

# 5 测试用例追踪

测试需求项标识	测试用例标识		
	TC001		
TR01	TC002		
	TC003		
	TC011		
TR11	TC012		
IKII	TC013		
	TC014		